

Rapport de projet de Data Mining

I/ Introduction

Ce projet a pour objectif de développer un système de recommandation d'images basé sur l'analyse de données visuelles et des préférences des utilisateurs. Il s'inscrit dans une démarche de Data Mining appliquée à un cas concret : recommander automatiquement des images pertinentes à partir d'une collection d'images et de profils utilisateurs.

L'approche adoptée repose sur plusieurs étapes successives. Tout d'abord, une collection d'images est constituée et enrichie avec des métadonnées (dimensions, format, etc.). Ensuite, des caractéristiques visuelles sont extraites, notamment les couleurs dominantes et des tags associés aux images. À partir de ces informations, des profils utilisateurs sont construits en fonction de leurs préférences (couleurs, taille, orientation, tags, images favorites).

Enfin, un système de recommandation est mis en place selon deux approches:

- Une approche basée sur la classification (filtrage par contenu),
- Une approche basée sur le clustering (regroupement d'images similaires).

L'ensemble du système est validé à l'aide de tests afin de garantir son bon fonctionnement et la pertinence des recommandations.

II/ Collecte de données

Les images utilisées dans ce projet proviennent de la plateforme Wikimedia Commons, qui propose des images libres de droits. Cela permet d'utiliser légalement les images tout en disposant de métadonnées associées (source, licence, EXIF).

La collection contient environ 100 images. Pour chaque image, plusieurs informations ont été stockées dans un fichier JSON (*images_metadata.json*) :

- Nom, dimensions, format, taille, URL source, informations EXIF (appareil, date, etc.)

Un second fichier (*images_labels.json*) contient les caractéristiques extraites :

- Couleurs dominantes (RGB), noms des couleurs, orientation (portrait/paysage/carré), catégorie de taille, tags associés

Enfin, un fichier *users.json* contient les profils utilisateurs simulés :

- Couleurs préférées, orientation préférée, taille préférée, tags préférés, images favorites

Ces données constituent la base du système de recommandation.

Les 3 fichiers JSON sont dans le rendu.

III/ Méthodologie

3.1 Extraction des caractéristiques

Les caractéristiques des images ont été extraites automatiquement.

Les couleurs dominantes sont obtenues à l'aide de l'algorithme KMeans (vu en TP). Chaque image est redimensionnée, puis les pixels sont regroupés en clusters afin d'identifier les couleurs principales.

Les couleurs RGB sont ensuite converties en noms de couleurs (gris, blanc, noir, etc.), ce qui permet de simplifier l'analyse.

D'autres caractéristiques sont également déterminées :

- Orientation (paysage, portrait, carré)
- Catégorie de taille (petite, moyenne, grande)
- Tags issus des métadonnées de la source

3.2 Construction du profil utilisateur

Les profils utilisateurs sont construits à partir des images favorites.

Pour chaque utilisateur, on extrait :

- Les couleurs dominantes fréquentes
- L'orientation majoritaire
- La taille la plus fréquente
- Les tags les plus présents

Permet de résumer les préférences des utilisateur sous forme de vecteur de caractéristiques.

3.3 Système de recommandation

Deux approches ont été implémentées.

Option A – Classification (filtrage par contenu)

Un modèle de classification (Random Forest) est entraîné pour chaque utilisateur :

- Images favorites → classe 1
- Autres images → classe 0

Le modèle apprend les préférences de l'utilisateur et prédit un score pour les images non vues. Les images avec les scores les plus élevés sont recommandées.

➤ **Avantage :** recommandations personnalisées

- Inconvénient : nécessite suffisamment de données


Option B – Clustering (KMeans)

Les images sont regroupées en clusters selon leurs caractéristiques.

Le principe est :

- Identifier les clusters des images favorites
 - Recommander d'autres images appartenant aux mêmes clusters
- Avantage : simple et rapide
 - Inconvénient : moins personnalisé

3.4 Diagramme d'architecture




IV/ Résultats

4.1 Visualisations

Plusieurs visualisations ont été réalisées : (ces visualisations sont disponibles dans la tâche 4)

- Nombre d'images par orientation
- Distribution des formats
- Histogramme des couleurs
- Tags les plus fréquents



4.2 Qualité des recommandations

Les tests montrent que :

- Les recommandations ne contiennent pas d'images déjà vues
- Elles correspondent globalement aux préférences des utilisateurs
- Les deux approches (A et B) donnent des résultats cohérents

Par exemple, pour un utilisateur préférant les images de type paysage avec des couleurs neutres (gris, blanc), les images recommandées respectent ces caractéristiques.

4.3 Observations

- Les recommandations de l'option A sont plus personnalisées
- L'option B est plus stable mais moins précise
- Les couleurs dominantes jouent un rôle important

4.4 Validation du système

Afin de vérifier le bon fonctionnement du système, une série de tests automatiques a été fait.

Les résultats des tests sont présentés ci-contre :

```
===== LANCEMENT DES TESTS =====  
OK - Nombre d'images suffisant : 100  
OK - Toutes les images existent dans le dossier images  
OK - Toutes les images ont des métadonnées  
OK - Les valeurs des métadonnées sont valides  
OK - L'extraction de couleurs retourne des RGB valides  
OK - La génération de profil utilisateur fonctionne  
OK - La fonction de recommandation retourne le bon nombre de résultats  
OK - Les recommandations ne sont pas déjà dans les favoris  
OK - Les recommandations correspondent globalement aux préférences (A=5/5, B=5/5)  
OK - Cas utilisateur inconnu géré  
OK - Cas profil vide géré  
===== TOUS LES TESTS SONT PASSÉS AVEC SUCCÈS =====
```

V/ Limitations et travaux futurs

Certaines limites ont été identifiées :

- Le nombre d'images est limité (~100)
- Les tags ne sont pas toujours pertinents
- Les profils utilisateurs sont simulés (pas réels)
- Les modèles restent simples

Améliorations possibles :

- Utiliser un dataset plus grand
- Améliorer l'extraction des tags (NLP)
- Ajouter des deep learning features (CNN)
- Implémenter une approche hybride (option C)

VI/ Conclusion

Ce projet a permis de mettre en œuvre un pipeline complet de Data Mining, depuis la collecte de données jusqu'à la recommandation d'images.

Les deux approches implémentées (classification et clustering) permettent de générer des recommandations pertinentes, validées par des tests automatiques.

Ce travail montre l'importance de la qualité des données et des features dans les systèmes de recommandation.

VII/ Références

- *Scikit-learn documentation*
- *Wikimedia Commons*
- *Cours et TP de Data Mining*